



# 卷积神经网络

- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习



# 常见的视觉任务

- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习



Person


Hammer




- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习




(a) Image classification



(b) Object localization



(c) Semantic segmentation

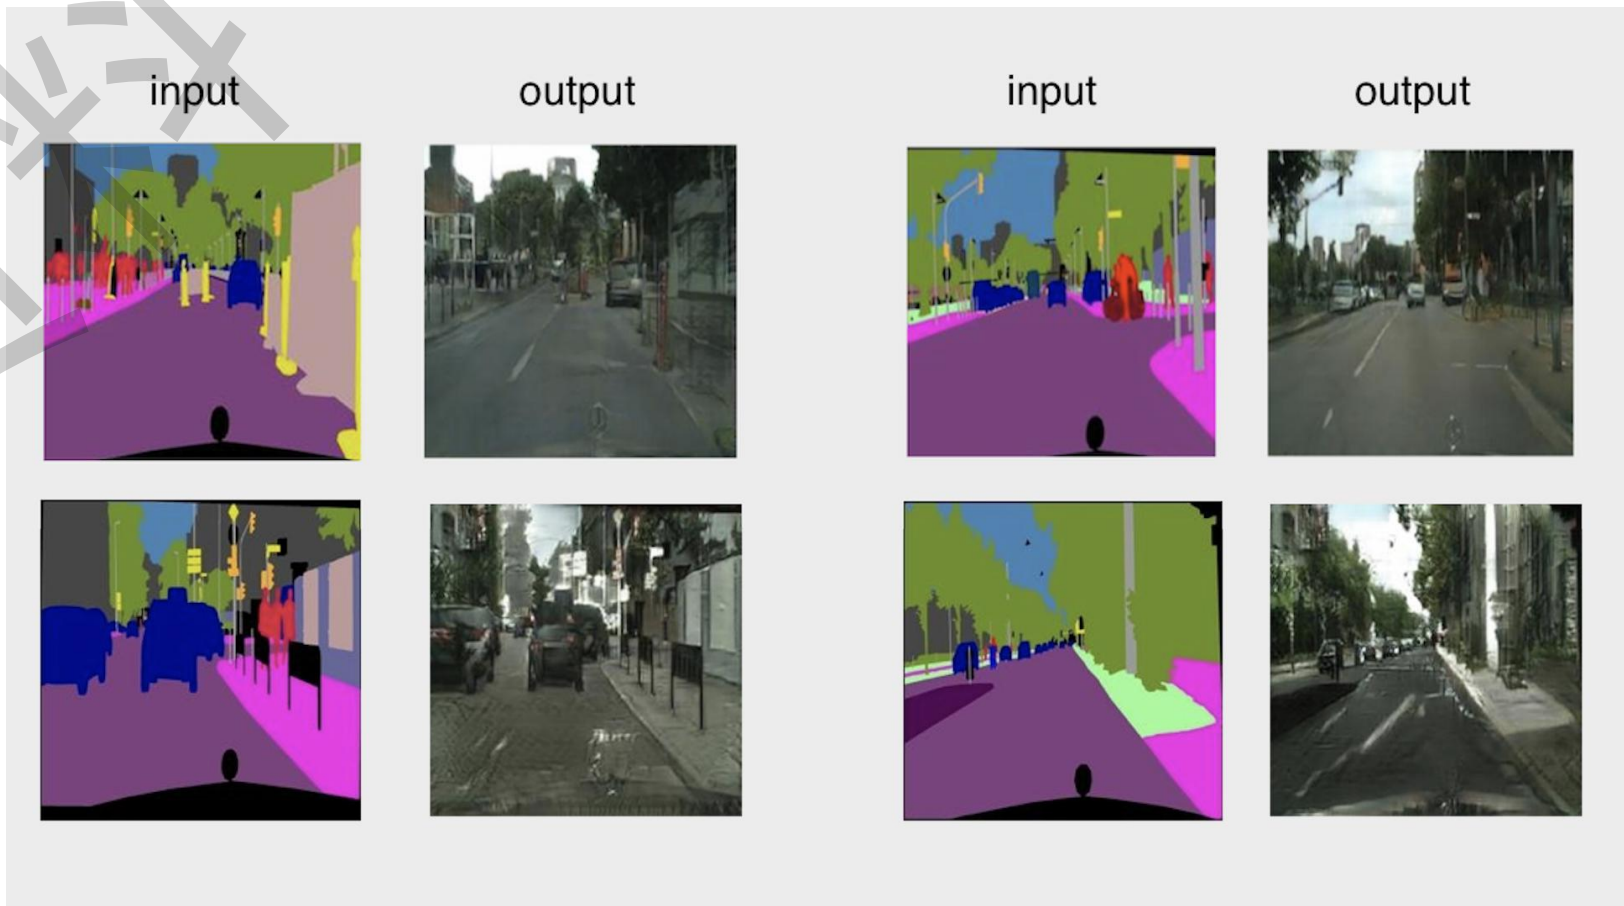


(d) Instance segmentation

- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习



- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习





## 常见的视觉任务

- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习




- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习





- 图像分类
- 目标检测
- 语义分割/实例分割
- 场景文字识别
- 图像生成
- 人体关键点检测
- 视频分类
- 度量学习



# 使用卷积神经网络的原因和效果


## 图像分类的样例



Response

```
{
  "log_id": "7275343294157017980",
  "result_num": 5,
  "result": [
    {
      "score": 0.860755,
      "root": "植物-果实/种子",
      "baike_info": [],
      "keyword": "蒲公英图片"
    },
    {
      "score": 0.669319,
      "root": "自然风景-天空",
      "keyword": "天空"
    },
    {
      "score": 0.488238,
      "root": "植物-菊科",
      "keyword": "蒲公英"
    },
    {
      "score": 0.294248,
```

## Revolution of Depth

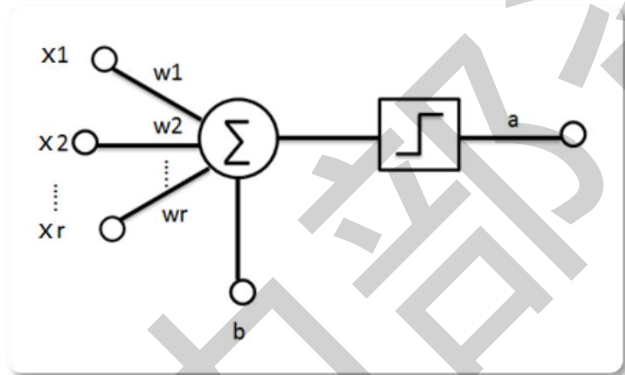


ImageNet 图像分类错误率 (top-5)




# >> 回忆一下神经网络结构

来一张神经网络：




单个神经元



# 卷积神经网络与计算机视觉

- 视觉类任务大部分都需要使用 CNN 技术

思考：为什么必须使用 CNN 呢？直接使用 DNN 可以吗？

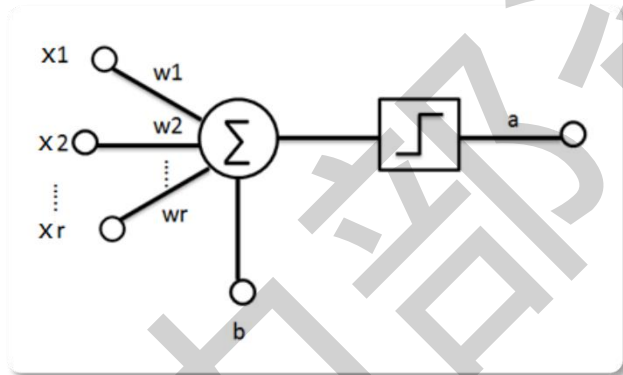


# >> 全连接神经网络：维度灾难

- 以200x200图像为例


- 全连接网络

- 输入层：40000维
    - 隐藏层：400000 神经元
    - 参数数目：160亿参数




单个神经元

$$f(\mathbf{w}\mathbf{x}+\mathbf{b})$$



内存消耗巨大  
计算量巨大  
训练时间过长



# >> 来个感性认识：CNN网络整体结构





# 使用卷积操作提取特征

# >> CNN网络整体结构



[INPUT - CONV - RELU - POOL - FC]

输入层


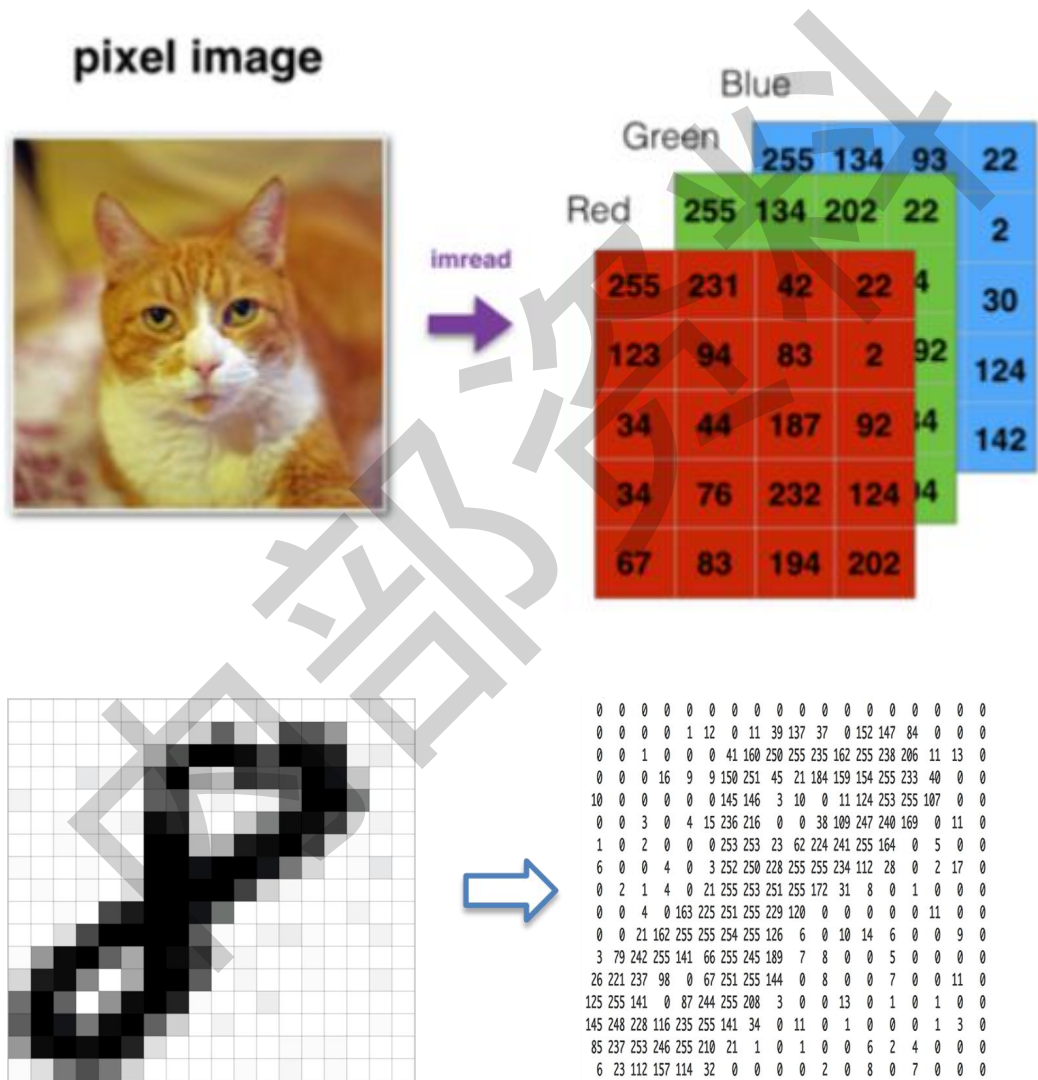
卷积层

激活函数

池化层

全连接层

## 二维卷积适用于图片存储矩阵



敲黑板：  
二维卷积核相当于计算窗口  
在窗口内做两个向量的内积



原图（灰度图）

灰度图是一个二维矩阵，每一个像素值都是 0-255 的整数

0 代表黑色，255 代表白色



-1	-1	0
-1	0	1
0	1	1

浮雕



## 图片经卷积后效果



1	1	1
1	-7	1
1	1	1

边缘





-1	-1	-1
-1	8	-1
-1	-1	-1

边缘


在线 Flash 示例:

<https://graphics.stanford.edu/courses/cs178/applets/convolution.html>


## 卷积层的具体工作过程



## >> 卷积层的具体工作过程




2个filter




特征图

6个filter

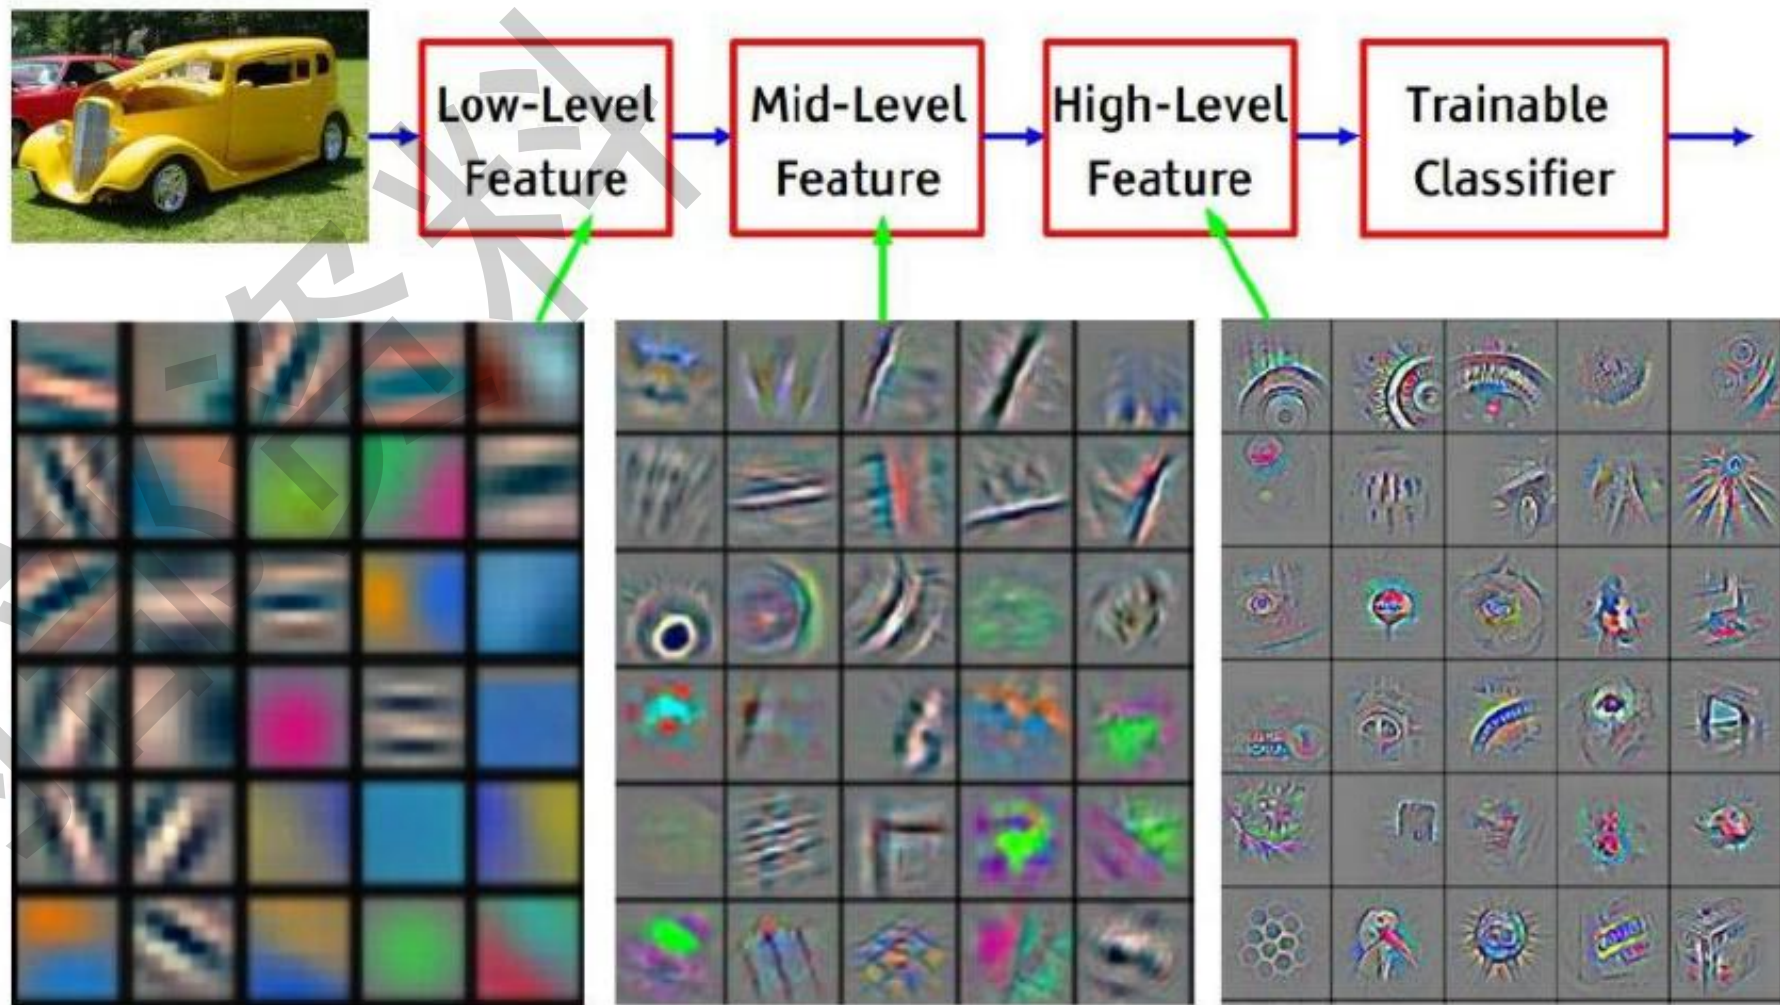


## >> 多个卷积层

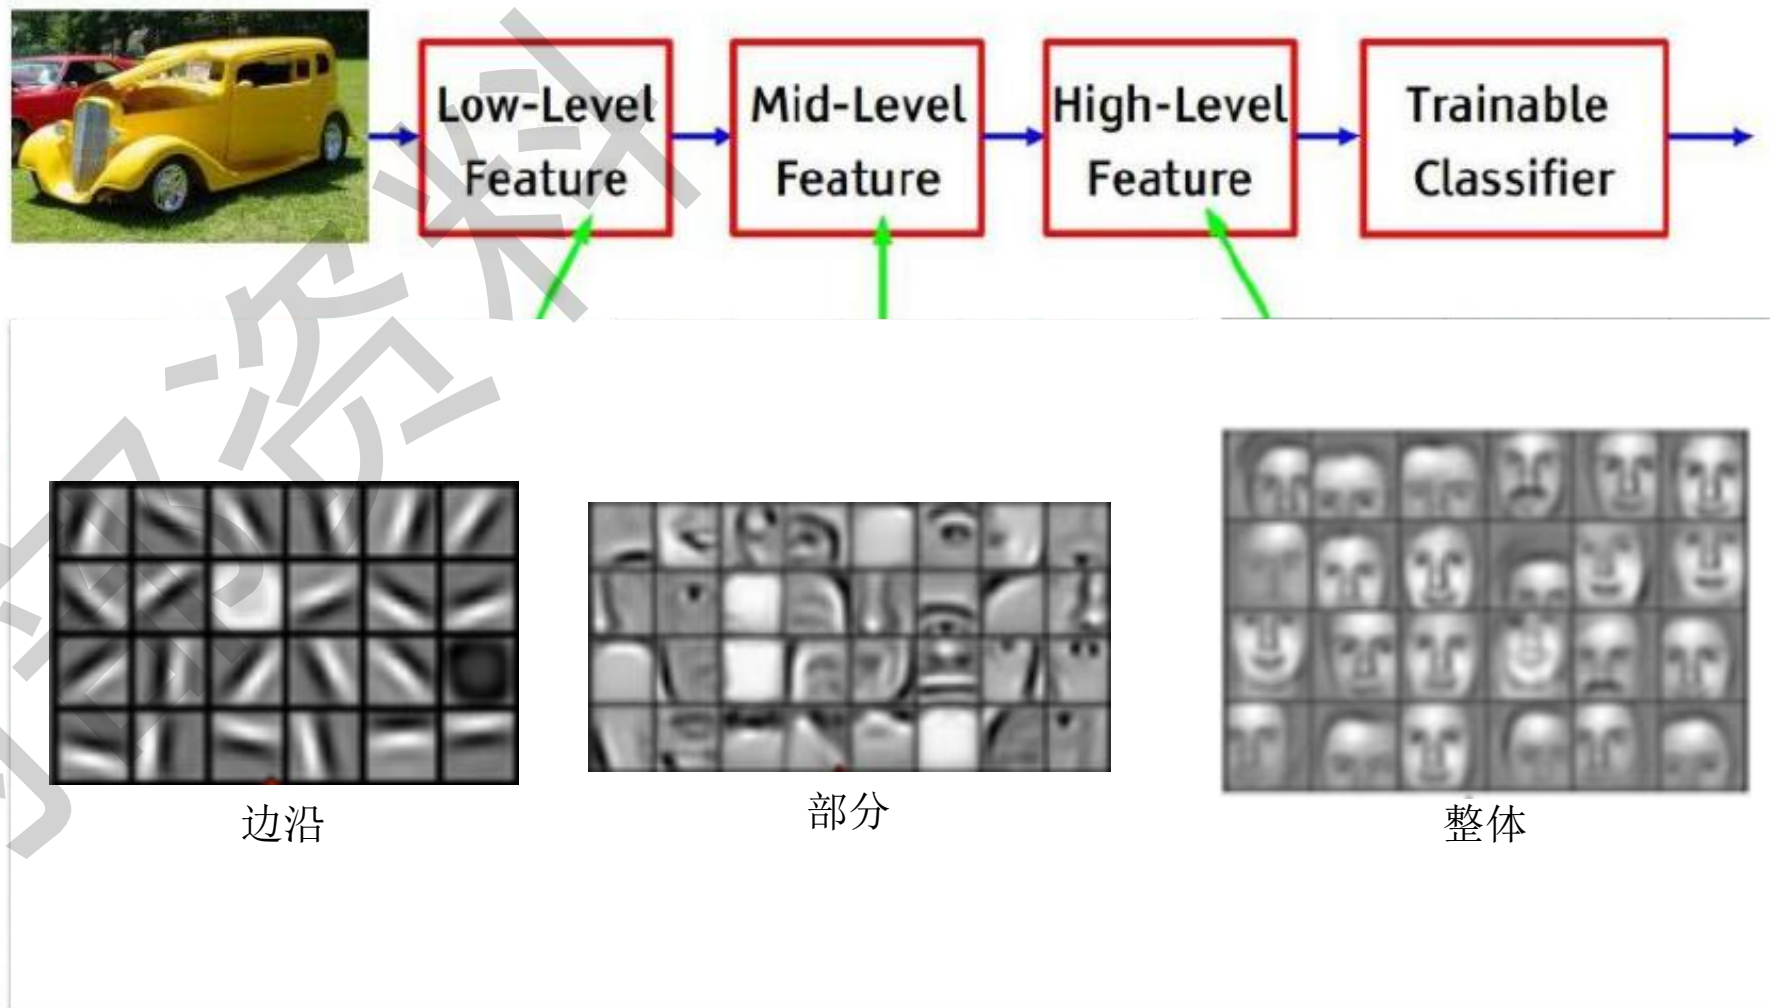




## 通过卷积操作提取特征



## 通过卷积操作提取特征




# 卷积核的分析与计算

# 卷积操作的参数——步长


步长stride: 反映了filter滑动一次的距离

步长为1


7 x 7 Input Volume




5 x 5 Output Volume





7 x 7 Input Volume



3 x 3 Output Volume



步长为2









## 卷积操作的参数——填充

Padding: 边界填充





## 特征图体积的计算

输入大小为:  $W_1 \times H_1 \times D_1$

需要指定的超参数: filter个数 ( $K$ ), filter大小 ( $F$ ), 步长 ( $S$ ), 边界填充 ( $P$ )

输出:

$$W_2 = (W_1 - F + 2P) / S + 1$$

$$H_2 = (H_1 - F + 2P) / S + 1$$

$$D_2 = K$$

一个例子:

输入: **32x32x3**

filters: **5x5** **10**↑

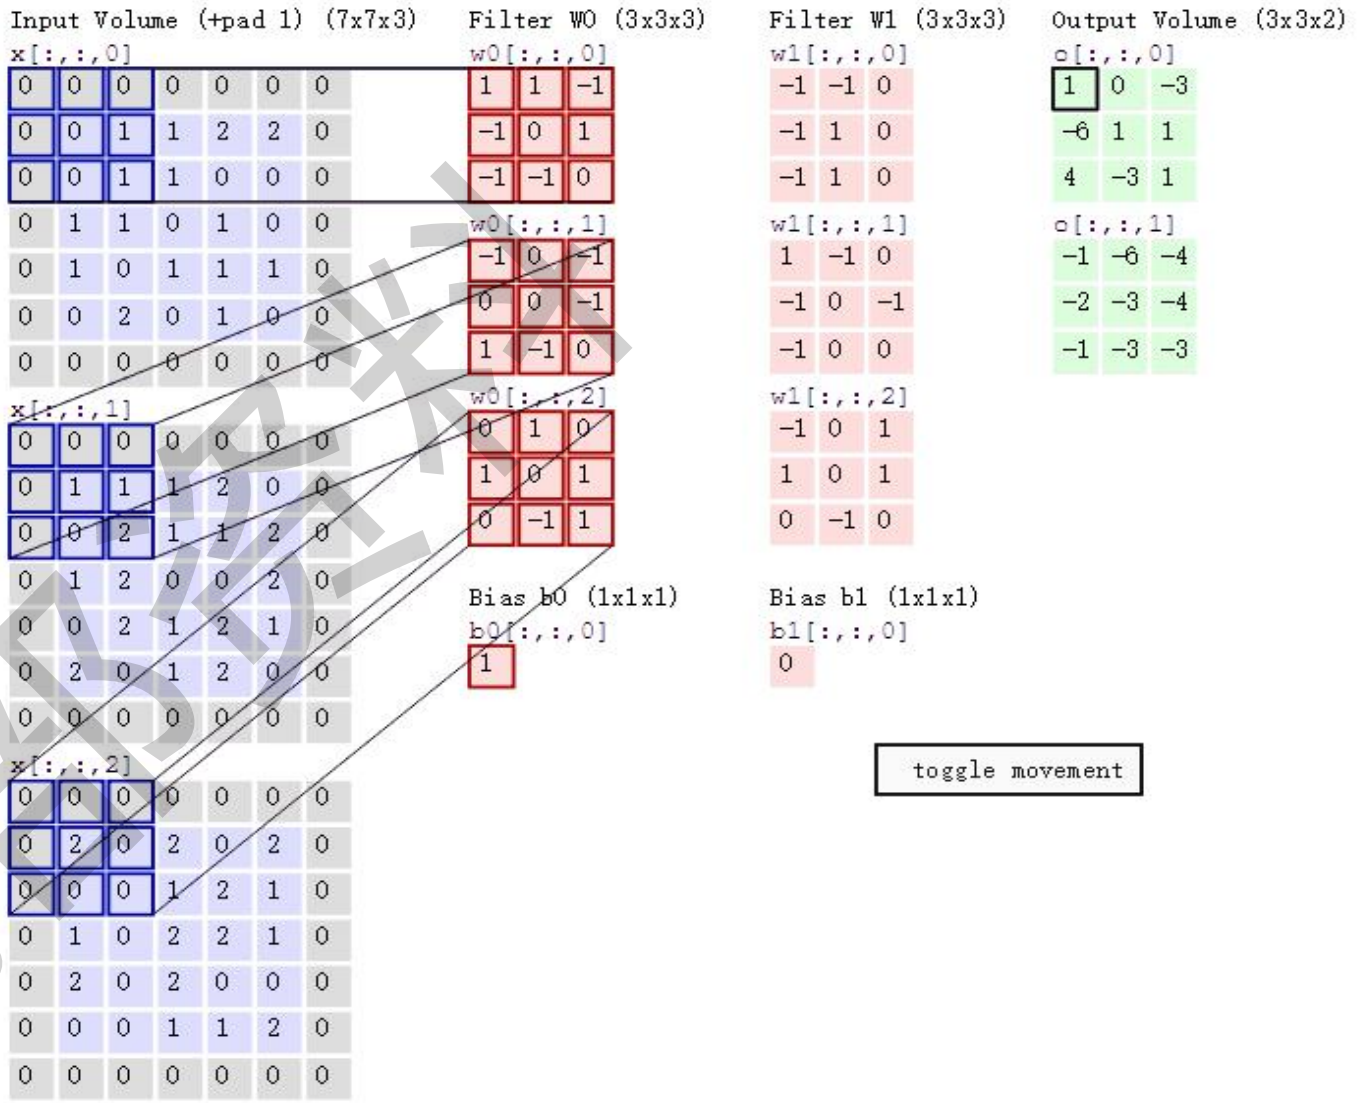
stride **1**, pad **2**

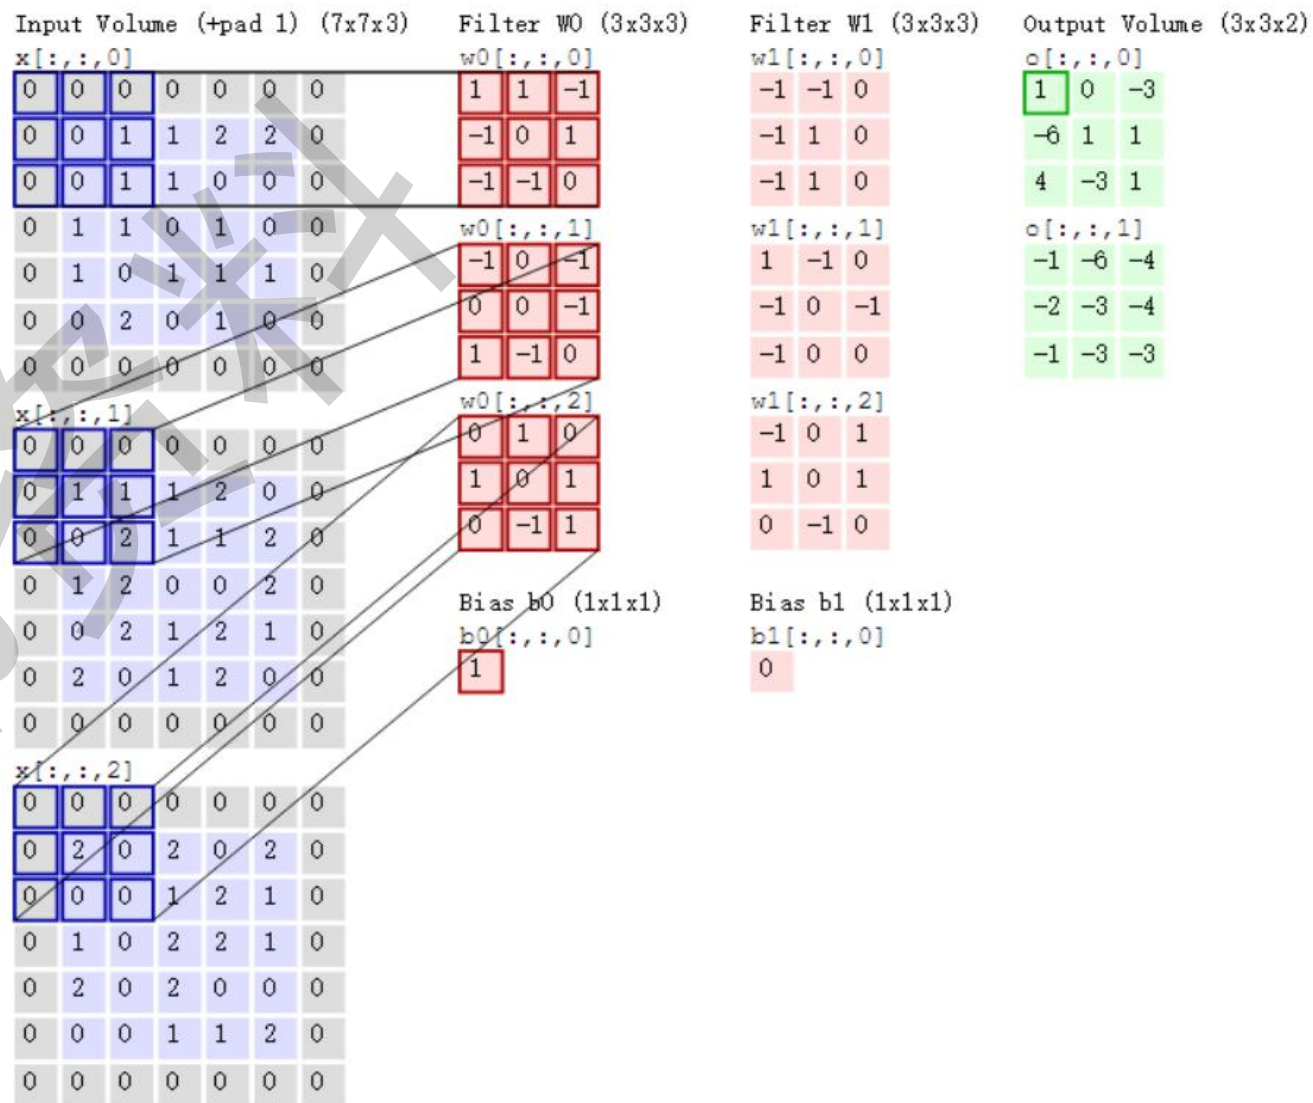


输出:

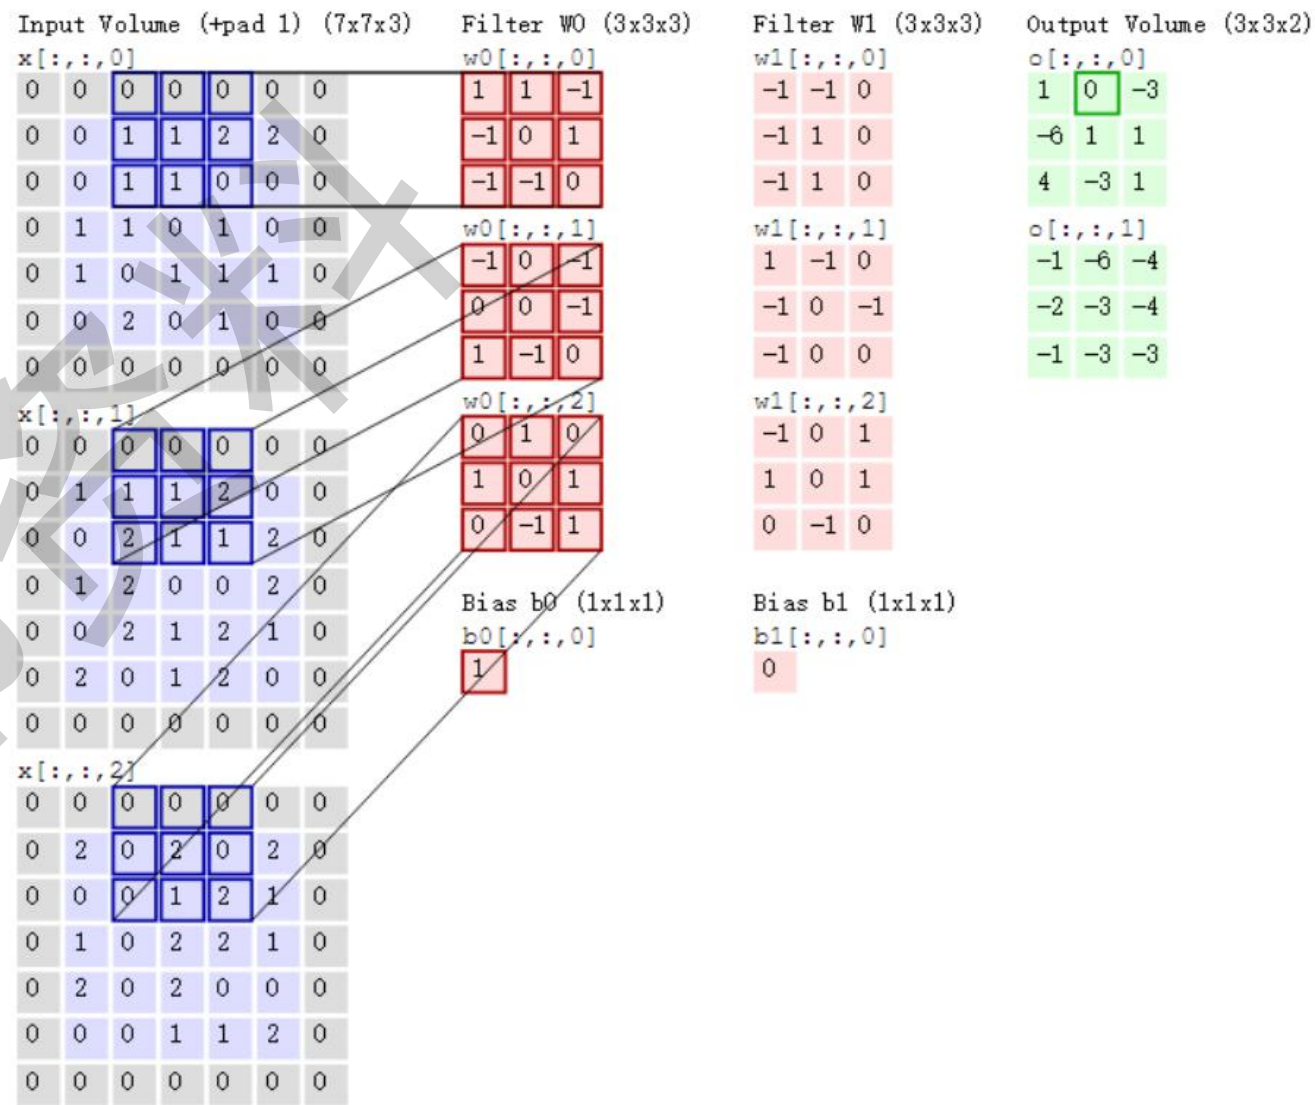
$$(32 + 2 * 2 - 5) / 1 + 1 = 32$$

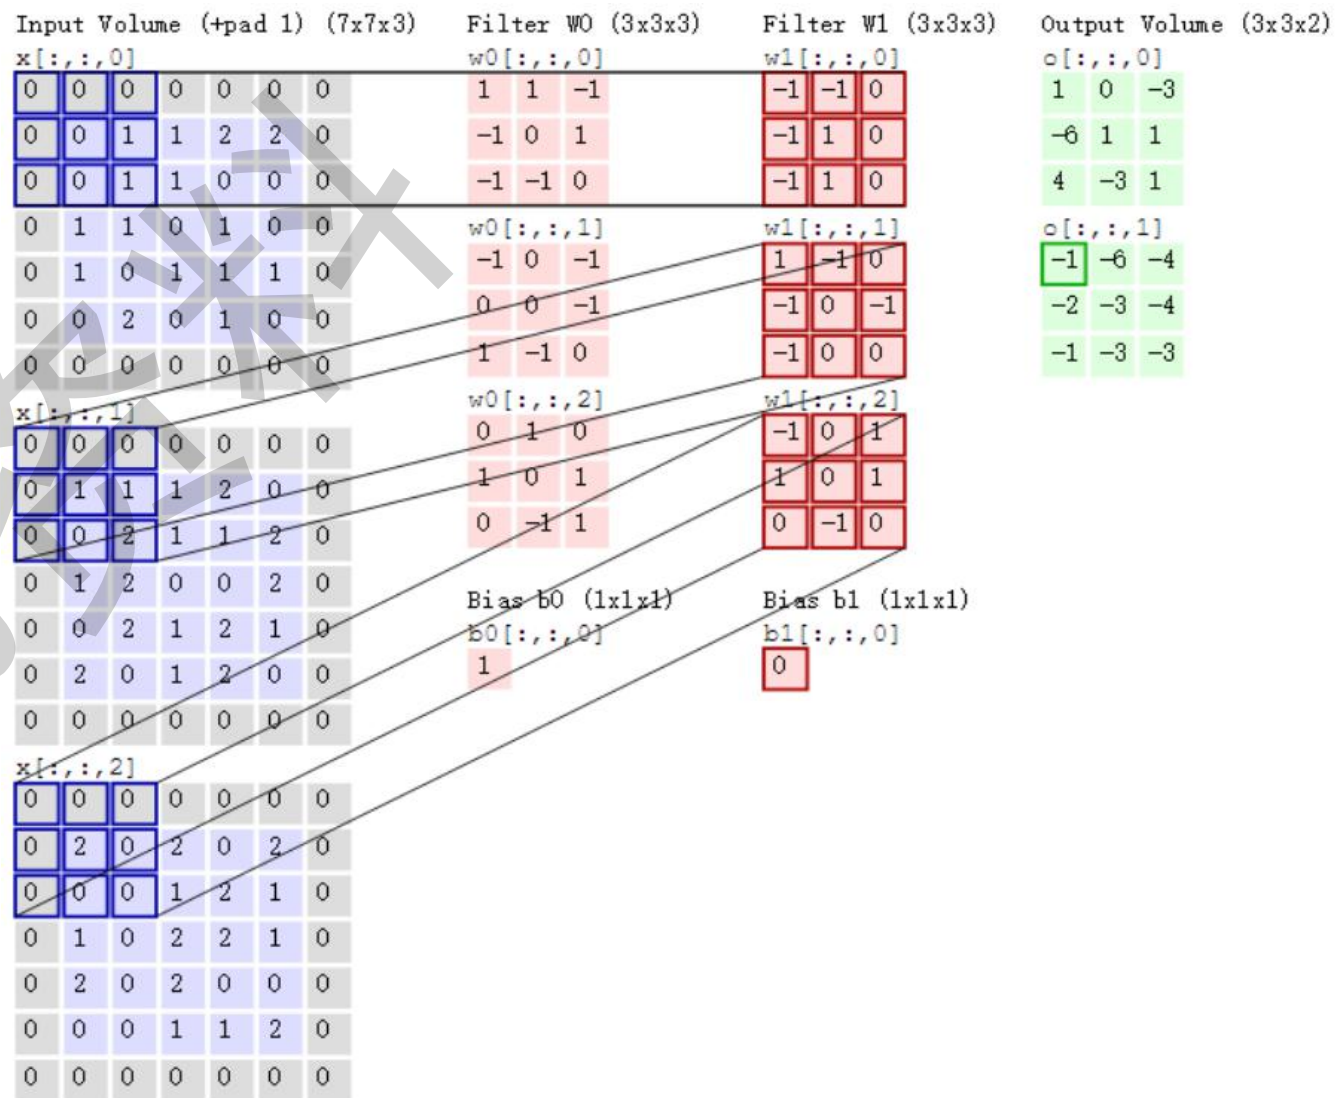
**32x32x10**

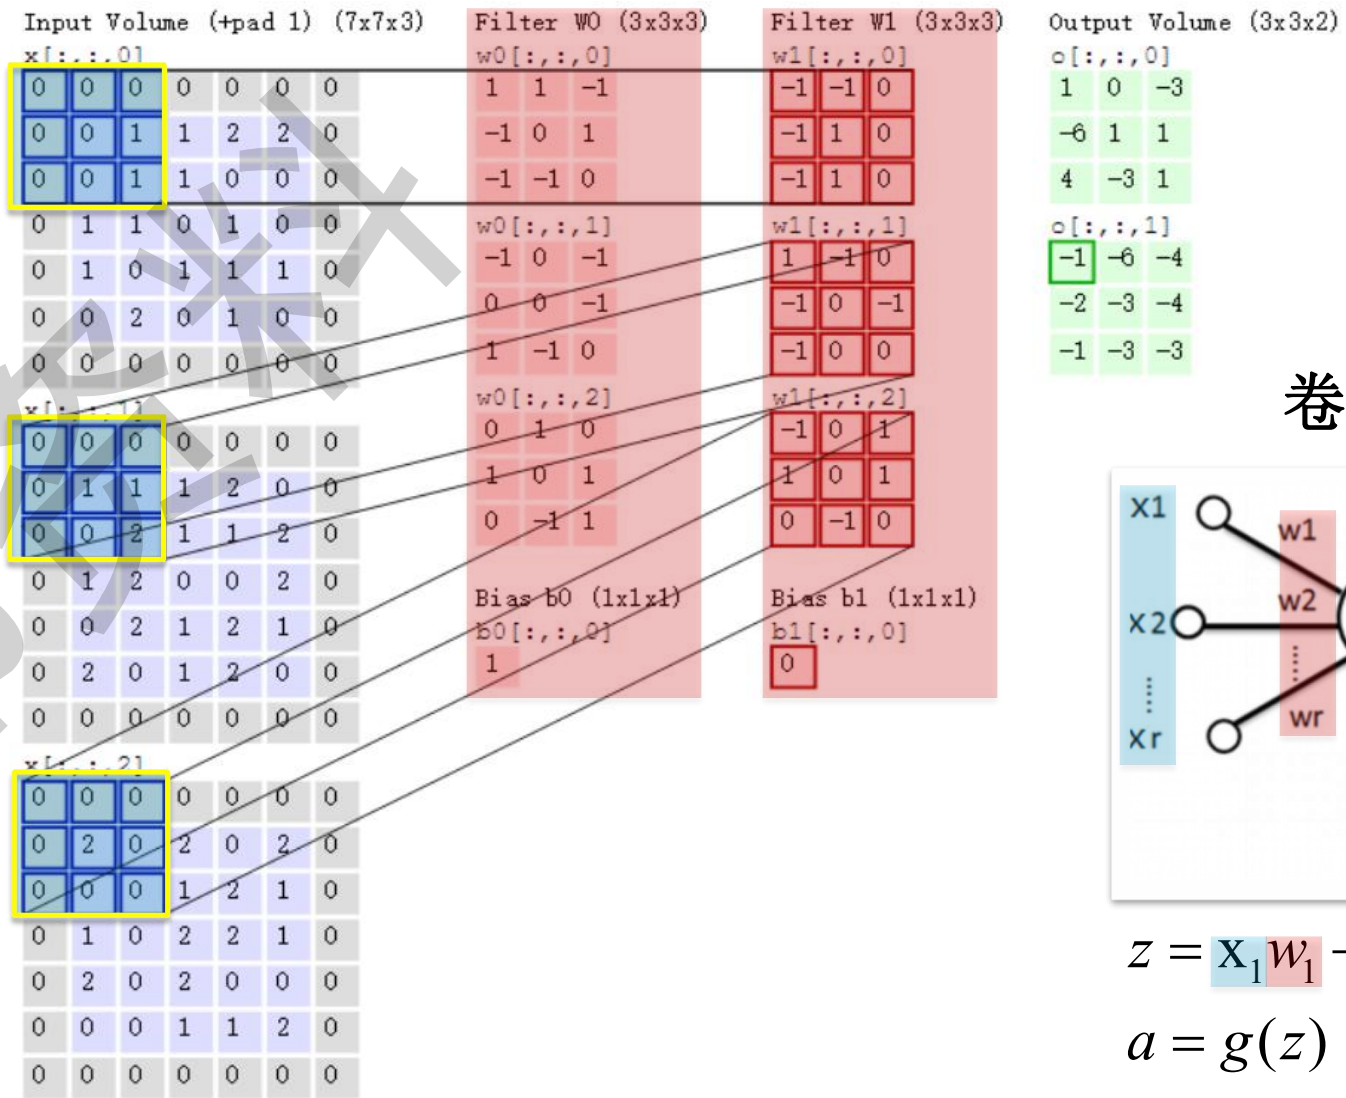




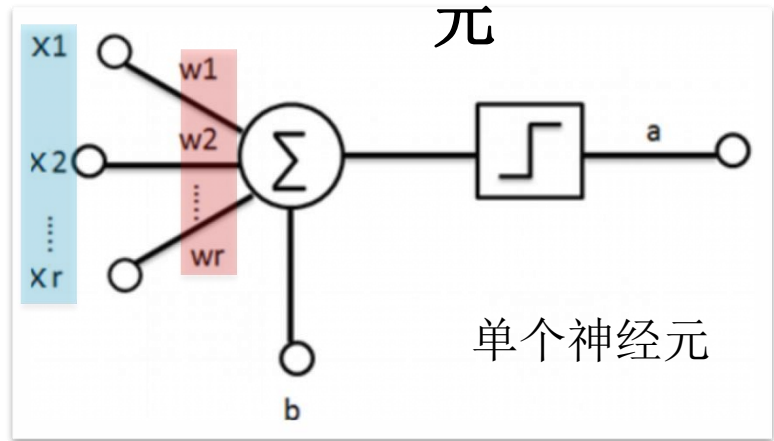








卷积核 = 神经  
元




$$z = x_1 w_1 + x_2 w_2 + \dots + x_r w_r + b$$

$$a = g(z)$$


局部连接

权值共享






权值共享



局部连接



全连接

权值共享极大的减少了参数的数量  
大大提高了计算速度，减少内存消耗

输入: **32x32x3**

filters: **5x5** **10**↑








内部资料

# 池化操作

- 使得原始图片的尺寸变小了





- 使得原始图片的尺寸变小了





# 池化层的运算






1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	9
8	

## 池化层pooling

- 通常池化操作是不重叠的  
– 即  $\text{size} = \text{stride}$
- 通常使用 max-pooling


最大池化：  
相当于计算窗口  
在窗口内取最大值



Feature map =  $10 * 10 * 1$



## CNN网络整体结构





谢谢大家

内部资料